

۱- ساختار حافظه کوتاه مدت بلند شامل سه گیت: input, forget, recall/output و همچنین یک cell state می باشد و ساختار GRU شامل دو گیت: reset, update می باشد و شکل کلی آن به صورت زیر می باشد:

### گیت فراموشی (Forget Gate)

این گیت تصمیم می گیرد کدام اطلاعات حفظ و کدام فراموش شود. اطلاعات ورودی گام جدید به همراه اطلاعات حالت نهان (Hidden State) گام قبلی به این گیت وارد می شوند و از تابع Sigmoid عبور می کنند. خروجی این تابع میان ۰ تا ۱ است.

$$f_t = \sigma (W_f \cdot [h_{t-1}, x_t] + b_f)$$

### گیت ورودی (Input Gate)

این گیت برای به روزرسانی مقادیر موجود در cell state تعبیه شده است. اطلاعات ورودی گام جدید، به همراه اطلاعات hidden state گام قبلی، به این گیت وارد می شوند و از تابع Sigmoid عبور می کنند تا این تابع تصمیم بگیرد کدام دور انداخته و کدام به روزرسانی شوند. همچنین اطلاعات ورودی گام جدید، به همراه اطلاعات hidden state گام قبلی، به تابع Tanh وارد می شوند تا مقادیرشان میان -۱ تا ۱ قرار بگیرد. در نهایت خروجی تابع Sigmoid و Tanh با هم ضرب می شوند تا تابع Sigmoid تصمیم بگیرد چه مقداری از خروجی تابع Tanh باید حفظ شوند.

$$i_t = \sigma (W_i \cdot [h_{t-1}, x_t] + b_i)$$

### گیت خروجی (Output Gate)

این گیت در نهایت تصمیم می گیرد که hidden state بعدی چه مقداری باشد. اول اطلاعات ورودی گام جدید به همراه اطلاعات hidden state گام قبلی به تابع Sigmoid وارد می شوند. مقدار به روز شده cell state به تابع Tanh وارد می شود. خروجی این دو تابع با هم ضرب می شود تا تصمیم گرفته شود hidden state چه اطلاعاتی را با خودش به گام بعدی ببرد. در نهایت cell state جدید و hidden state جدید به گام زمانی بعدی منتقل می شوند.

$$o_t = \sigma (W_o [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t * \tanh (C_t)$$

Cell state:

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

### گیت به روزرسانی (Update Gate)

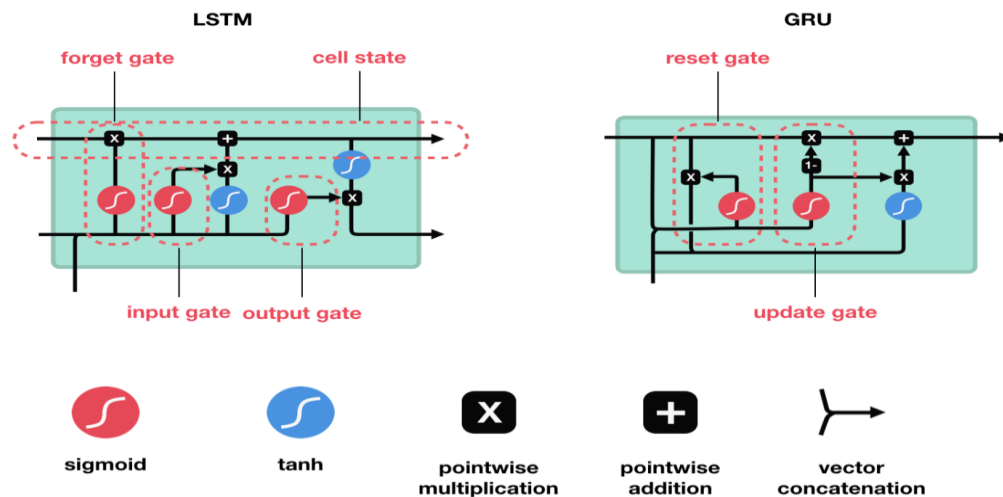
این گیت دقیقاً مانند دو گیت فراموشی (Forget Gate) و ورودی (Input Gate) در شبکه LSTM عمل می کند. این گیت تصمیم می گیرد چه مقدار از اطلاعاتی که در گام های قبلی داشتیم، نگه داریم. در این گیت مقدار ورودی جدید ( $x_t$ ) به همراه مقدار حالت نهان گام قبلی ( $h_{t-1}$ ) در وزن متناظر خود ضرب و سپس با هم جمع می شوند و به یک تابع sigmoid وارد می شوند تا خروجی میان بازه ۰ تا ۱ قرار بگیرد. در زمان آموزش شبکه این وزن ها هر بار به روزرسانی می شوند.

$$z_t = \sigma(W^{(z)}x_t + U^{(z)}h_{t-1})$$

## گیت تنظیم مجدد (Reset Gate)

این گیت تصمیم می‌گیرد چه مقدار از اطلاعات گذشته، یعنی اطلاعات گام‌های قبلی، فراموش شود. در اینجا هم مقدار ورودی جدید ( $x_t$ )، به همراه مقدار حالت نهان گام قبلی ( $h_{t-1}$ )، در وزن متناظر خود ضرب و سپس با هم جمع می‌شوند و به یک تابع sigmoid وارد می‌شوند تا خروجی بین بازه ۰ تا ۱ قرار بگیرد. تفاوتی که با گیت بهروزرسانی دارد این است که وزن‌هایی که مقدار ورودی و حالت نهان گام قبلی در آن ضرب می‌شوند متفاوت است و این یعنی بردارهای خروجی در اینجا با بردار خروجی که در گیت بهروزرسانی داریم متفاوت می‌باشد.

$$r_t = \sigma(W^{(r)}x_t + U^{(r)}h_{t-1})$$



تفاوت اصلی بین GRU و LSTM این است که GRU دارای دو گیت reset و update است. در حالی که LSTM دارای سه گیت است که input، output، forget هستند. GRU پیچیدگی کمتری نسبت به LSTM دارد زیرا تعداد گیت‌های کمتری دارد. اگر مجموعه داده کوچک است، GRU ترجیح داده می‌شود در غیر این صورت LSTM برای مجموعه داده بزرگتر ترجیح داده می‌شود. GRU هیچ حافظه داخلی ندارد، و مانده LSTM گیت خروجی ندارد.

۲- کتابخانه‌های مورد نیاز :

```
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
from sklearn.model_selection import train_test_split
import glob
from sklearn.preprocessing import MinMaxScaler
from tensorflow import keras
import numpy
import math
from keras.models import Sequential
from keras.layers import Dense, LSTM, Dropout, GRU
from sklearn.metrics import mean_squared_error
from keras.engine.input_layer import Input
from sklearn.metrics import confusion_matrix
```

در ابتدا تمامی دیتاست را میخوانیم و فایل های خالی را حذف می کنیم و سپس بر روی باقیمانده آنها بازه سال اخیر را اعمال می کنیم و ستون های شامل حروف را حذف می کنیم و در نهایت ادغام می کنیم :

```
dataset = pd.DataFrame(columns=['<DTYYYYMMDD>'])
path = "/content/*.*)"
for file in glob.glob(path):
    print(file)
    data = pd.read_csv(file, delimiter=',', encoding='utf-16_le')
    if not data.empty:

        # Select a range of data
        data = pd.DataFrame(data[(data['<DTYYYYMMDD>'] > 20210523)], columns=data.columns).reset_index(drop=True)

        #delete string columns
        drop_attrs = [0, 10, 11]
        data.drop(data.columns[drop_attrs], axis=1, inplace=True)

        #merge
        dataset = pd.merge(dataset, data, left_on='<DTYYYYMMDD>', right_on='<DTYYYYMMDD>', how="right", sort=False)
```

سپس مجموعه داده ساخته شده را نرمالایز می کنیم و چک میکنیم ایا مقدار null داریم یا نه و سپس ایندکس آن را در می اوریم و حذف میکنیم:

```
1 dataset.shape
```

(238, 145)

```
1 ds = MinMaxScaler().fit_transform(dataset)
2 ds = pd.DataFrame(ds)
3 ds.isnull().values.any()
```

True

```
1 rows_with_nan = []
2 for index, row in ds.iterrows():
3     is_nan_series = row.isnull()
4     if is_nan_series.any():
5         rows_with_nan.append(index)
6 rows_with_nan
```

[201]

```
1 ds = ds.drop([201],axis=0)
```

```
1 ds.shape
```

(237, 145)

برای لیبل دیتاست از فایلی که شامل شاخص کل است استفاده می کنیم و مقدار ستون close هر سطر را منهای سطر قبلی کرده و در صورتی که بزرگتر صفر بوده مقدار ۱ به عنوان لیبل آن سطر می دهیم و در صورتی که کوچکتر از صفر بود مقدار ۰ به عنوان لیبل داده میشود:

```
def label (data):
    label =[]
    for i in range(1,len(data)) :
        var = data[i] - data[i-1]
        if var < 0:
            label.append(0)
        else:
            label.append(1)
    return np.array(label)
```

```
path = '/content/IRX6XTPI0009.csv'
dt = pd.read_csv(path, delimiter=',', encoding='utf-16_le')
dt = pd.DataFrame(dt[(dt['<DTYYYYMMDD>'] > 20210522)], columns=dt.columns).reset_index(drop=True)
labels = label(dt['<CLOSE>'])
```

سپس برای اینکه سری زمانی برای مجموعه داده آماده شده بسازیم به صورت زیر عمل می‌کنیم و دیتا و برچسب‌ها را دسته‌بندی می‌کنیم:

```
1 def batch_ds (dt, lbl, batchsize):
2     data_time=[]
3     labels=label(lbl)
4     label_time=[]
5     for i in range(batchsize, len(dt)):
6         data_time.append(dt[i - batchsize : i ])
7         label_time.append(labels[i-1])
8     return np.array(data_time), np.array(label_time)
```

```
1 data_timestep, label_timestep = batch_ds(ds, labels, batchsize=10)
```

```
1 data_timestep.shape
```

```
(227, 10, 145)
```

در نهایت داده را به سه دسته تقسیم می‌کنیم:

```
X_train, X_test, y_train, y_test = train_test_split(data_timestep, label_timestep, test_size=0.3, random_state=22)
X_test , X_val, y_test, y_val =train_test_split(X_test,y_test,test_size=0.33,random_state=22)
```

## LSTM MODEL:

با استفاده از مدل `sequential` کراس مدل ترتیبی ایجاد کرده و از `tf.keras.layers.LSTM` که قبلاً `import` شده است به صورت آماده استفاده می‌کنیم و در نهایت یک لایه `dense` برای رسیدن به یک خروجی (۱ یا ۰) اضافه می‌کنیم:

```

1 model = Sequential()
2 model.add(Input(shape = (10,145)))
3 model.add(LSTM(4))
4 model.add(Dense(1, activation = 'relu'))

```

```

1 model.compile(loss='mean_squared_error', optimizer='adam',metrics=["acc"])
2 model.fit(X_train, y_train, epochs=5)

```

دقت به دست آمده بر روی مجموعه داده آموزش و سپس ارزیابی مدل:

```

Epoch 5/5
5/5 [=====] - 0s 7ms/step - loss: 0.1969 - acc: 0.7342
<keras.callbacks.History at 0x7f21fc20ebd0>

```

```

1 model.evaluate(X_test,y_test)

```

```

2/2 [=====] - 0s 9ms/step - loss: 0.1344 - acc: 0.8696
[0.13442111015319824, 0.8695651888847351]

```

ماتریس در هم ریختگی:

```

1 y_pred = model.predict(X_val)

```

```

1 confusion_matrix(y_val, y_pred.round())

```

```

array([[ 0,  4],
       [ 0, 19]])

```

از نتیجه دریافت میشود که شاخص ما صعودی است

نتیجه استفاده از ابعاد مختلف لایه نهان: نتیجه گرفته می شود که اگر ابعاد لایه مخفی بیشتر از حدی شود شبکه توانایی یادگیری خودش را از دست می دهد و نسبت به تغییرات آموزش کمتری دارد.

```

1 model = Sequential()
2 model.add(Input(shape = (10,145)))
3 model.add(LSTM(10))
4 model.add(Dense(1, activation = 'relu'))

```

```

1 model.compile(loss='mean_squared_error', optimizer='adam',metrics=["acc"])
2 model.fit(X_train, y_train, epochs=5)

```

```

Epoch 1/5
5/5 [=====] - 3s 8ms/step - loss: 0.7342 - acc: 0.2658
Epoch 2/5
5/5 [=====] - 0s 10ms/step - loss: 0.7342 - acc: 0.2658
Epoch 3/5
5/5 [=====] - 0s 8ms/step - loss: 0.7342 - acc: 0.2658
Epoch 4/5
5/5 [=====] - 0s 8ms/step - loss: 0.7342 - acc: 0.2658
Epoch 5/5
5/5 [=====] - 0s 9ms/step - loss: 0.7342 - acc: 0.2658
<keras.callbacks.History at 0x7f21ebf5ca10>

```

```

1 model = Sequential()
2 model.add(Input(shape = (10,145)))
3 model.add(LSTM(5))
4 model.add(Dense(1, activation = 'sigmoid'))

```

```

1 model.compile(loss='mean_squared_error', optimizer='adam', metrics=["acc"])
2 model.fit(X_train, y_train, epochs=5)

```

```

Epoch 1/5
5/5 [=====] - 2s 8ms/step - loss: 0.2569 - acc: 0.4494
Epoch 2/5
5/5 [=====] - 0s 8ms/step - loss: 0.2198 - acc: 0.6899
Epoch 3/5
5/5 [=====] - 0s 7ms/step - loss: 0.2053 - acc: 0.7342
Epoch 4/5
5/5 [=====] - 0s 7ms/step - loss: 0.2010 - acc: 0.7342
Epoch 5/5
5/5 [=====] - 0s 7ms/step - loss: 0.1986 - acc: 0.7342
<keras.callbacks.History at 0x7f21e2b22d90>

```

```

1 model = Sequential()
2 model.add(Input(shape = (10,145)))
3 model.add(LSTM(15))
4 model.add(Dense(1, activation = 'sigmoid'))

```

```

1 model.compile(loss='mean_squared_error', optimizer='adam', metrics=["acc"])
2 model.fit(X_train, y_train, epochs=5)

```

```

Epoch 1/5
5/5 [=====] - 2s 8ms/step - loss: 0.2009 - acc: 0.7342
Epoch 2/5
5/5 [=====] - 0s 6ms/step - loss: 0.1990 - acc: 0.7342
Epoch 3/5
5/5 [=====] - 0s 7ms/step - loss: 0.1975 - acc: 0.7342
Epoch 4/5
5/5 [=====] - 0s 7ms/step - loss: 0.1966 - acc: 0.7342
Epoch 5/5
5/5 [=====] - 0s 7ms/step - loss: 0.1959 - acc: 0.7342
<keras.callbacks.History at 0x7f21e24a0690>

```

## GRU MODEL:

```

model = Sequential()
model.add(Input(shape = (10,145)))
model.add(GRU(4))
model.add(Dense(1, activation = 'sigmoid'))

```

```

model.compile(loss='mean_squared_error', optimizer='adam', metrics=["acc"])
model.fit(data_timestep, label_timestep, epochs=5)

```

دقت مدل بر روی مجموعه آموزش و ارزیابی آن:

```

Epoch 5/5
8/8 [=====] - 0s 7ms/step - loss: 0.2052 - acc: 0.7709
<keras.callbacks.History at 0x7f21ded88190>

```

```

1 model.evaluate(X_test,y_test)

```

```

2/2 [=====] - 0s 14ms/step - loss: 0.1257 - acc: 0.8696
[0.12568818032741547, 0.8695651888847351]

```

```
1 y_pred = model.predict(X_val)

1 confusion_matrix(y_val, y_pred.round())

array([[ 0, 4],
       [ 0, 19]])
```

ابعاد مختلف {۲۵و۱۵و۵} را امتحان کرده و تنها تفاوت در سرعت همگرایی می باشد و هرچه بیشتر باشد سرعت همگرایی نیز بیشتر است:

```
1 model = Sequential()
2 model.add(Input(shape = (10,145)))
3 model.add(GRU(5))
4 model.add(Dense(1, activation = 'sigmoid'))

1 model.compile(loss='mean_squared_error', optimizer='adam',metrics=["acc"])
2 model.fit(data_timestep, label_timestep, epochs=5)
```

```
Epoch 1/5
8/8 [=====] - 2s 7ms/step - loss: 0.2712 - acc: 0.4670
Epoch 2/5
8/8 [=====] - 0s 7ms/step - loss: 0.1894 - acc: 0.7709
Epoch 3/5
8/8 [=====] - 0s 7ms/step - loss: 0.1799 - acc: 0.7709
Epoch 4/5
8/8 [=====] - 0s 6ms/step - loss: 0.1813 - acc: 0.7709
Epoch 5/5
8/8 [=====] - 0s 6ms/step - loss: 0.1816 - acc: 0.7709
<keras.callbacks.History at 0x7f21e8192b50>
```

```
1 model = Sequential()
2 model.add(Input(shape = (10,145)))
3 model.add(GRU(10))
4 model.add(Dense(1, activation = 'sigmoid'))

1 model.compile(loss='mean_squared_error', optimizer='adam',metrics=["acc"])
2 model.fit(data_timestep, label_timestep, epochs=5)
```

```
Epoch 1/5
8/8 [=====] - 2s 9ms/step - loss: 0.2297 - acc: 0.6123
Epoch 2/5
8/8 [=====] - 0s 7ms/step - loss: 0.1857 - acc: 0.7709
Epoch 3/5
8/8 [=====] - 0s 7ms/step - loss: 0.1809 - acc: 0.7709
Epoch 4/5
8/8 [=====] - 0s 8ms/step - loss: 0.1809 - acc: 0.7709
Epoch 5/5
8/8 [=====] - 0s 7ms/step - loss: 0.1805 - acc: 0.7709
<keras.callbacks.History at 0x7f21ddff4590>
```

```
1 model = Sequential()
2 model.add(Input(shape = (10,145)))
3 model.add(GRU(25))
4 model.add(Dense(1, activation = 'sigmoid'))

1 model.compile(loss='mean_squared_error', optimizer='adam',metrics=["acc"])
2 model.fit(data_timestep, label_timestep, epochs=5)
```

```
Epoch 1/5
8/8 [=====] - 2s 8ms/step - loss: 0.1857 - acc: 0.7665
Epoch 2/5
8/8 [=====] - 0s 8ms/step - loss: 0.1812 - acc: 0.7709
Epoch 3/5
8/8 [=====] - 0s 8ms/step - loss: 0.1842 - acc: 0.7709
Epoch 4/5
8/8 [=====] - 0s 9ms/step - loss: 0.1844 - acc: 0.7709
Epoch 5/5
8/8 [=====] - 0s 8ms/step - loss: 0.1795 - acc: 0.7709
<keras.callbacks.History at 0x7f21db49d950>
```

در این مسئله بهترین دقت مدل 77% GRU و بهترین دقت مدل 73% LSTM می باشد، علت آن کوچک بودن مجموعه داده می باشد

۳- با استفاده از ۲ لایه LSTM از Keras مانده قبل عمل می کنیم و خروجی اولی را به عنوان ورودی به لایه بعدی می دهیم:

```
1 model = Sequential()
2 model.add(LSTM(16, input_shape=(10,145), return_sequences=True))
3 model.add(Dropout(0.2))
4 model.add(LSTM(8, input_shape=(10,16), return_sequences=False))
5 model.add(Dropout(0.2))
6 model.add(Dense(4,activation='relu'))
7 model.add(Dense(1,activation='relu'))
```

نتیجه مدل بر روی داده آموزش

```
1 model.compile(loss='mean_squared_error', optimizer='adam',metrics=["acc"])
2 model.fit(data_timestep, label_timestep, epochs=10,callbacks=[tensorboard_callback])
```

```
Epoch 1/10
8/8 [=====] - 6s 19ms/step - loss: 0.4761 - acc: 0.2996
Epoch 2/10
8/8 [=====] - 0s 20ms/step - loss: 0.2164 - acc: 0.7093
Epoch 3/10
8/8 [=====] - 0s 18ms/step - loss: 0.2162 - acc: 0.7445
Epoch 4/10
8/8 [=====] - 0s 19ms/step - loss: 0.2081 - acc: 0.7445
Epoch 5/10
8/8 [=====] - 0s 23ms/step - loss: 0.1991 - acc: 0.7533
Epoch 6/10
8/8 [=====] - 0s 19ms/step - loss: 0.2048 - acc: 0.7048
Epoch 7/10
8/8 [=====] - 0s 19ms/step - loss: 0.2013 - acc: 0.7533
Epoch 8/10
8/8 [=====] - 0s 18ms/step - loss: 0.1919 - acc: 0.7357
Epoch 9/10
8/8 [=====] - 0s 18ms/step - loss: 0.1917 - acc: 0.7621
Epoch 10/10
8/8 [=====] - 0s 18ms/step - loss: 0.1962 - acc: 0.7533
<keras.callbacks.History at 0x7f21d23c0390>
```


نتیجه ارزیابی مدل:

```
1 model.evaluate(X_test,y_test)
```


```
2/2 [=====] - 2s 12ms/step - loss: 0.1230 - acc: 0.8696
[0.12303298711776733, 0.8695651888847351]
```



epoch\_loss  
tag: epoch\_loss



epoch\_acc  
tag: epoch\_acc



نتیجه سه ابعاد متفاوت:

با ابعاد کوچکتر نمیتوان نتیجه مطلوبی دریافت کرد

```
1 model = Sequential()
2 model.add(LSTM(8, input_shape=(10,145), return_sequences=True))
3 model.add(Dropout(0.2))
4 model.add(LSTM(4, input_shape=(10,8), return_sequences=False))
5 model.add(Dropout(0.2))
6 model.add(Dense(2,activation='relu'))
7 model.add(Dense(1,activation='relu'))
```

```
1 model.compile(loss='mean_squared_error', optimizer='adam',metrics=["acc"])
2 model.fit(data_timestep, label_timestep, epochs=10,callbacks=[tensorboard_callback])
```

```
Epoch 1/10
8/8 [=====] - 4s 18ms/step - loss: 0.7709 - acc: 0.2291
Epoch 2/10
8/8 [=====] - 0s 18ms/step - loss: 0.7709 - acc: 0.2291
Epoch 3/10
8/8 [=====] - 0s 20ms/step - loss: 0.7709 - acc: 0.2291
Epoch 4/10
8/8 [=====] - 0s 18ms/step - loss: 0.7709 - acc: 0.2291
Epoch 5/10
8/8 [=====] - 0s 18ms/step - loss: 0.7709 - acc: 0.2291
Epoch 6/10
8/8 [=====] - 0s 19ms/step - loss: 0.7709 - acc: 0.2291
Epoch 7/10
8/8 [=====] - 0s 19ms/step - loss: 0.7709 - acc: 0.2291
Epoch 8/10
8/8 [=====] - 0s 18ms/step - loss: 0.7709 - acc: 0.2291
Epoch 9/10
8/8 [=====] - 0s 18ms/step - loss: 0.7709 - acc: 0.2291
Epoch 10/10
8/8 [=====] - 0s 17ms/step - loss: 0.7709 - acc: 0.2291
<keras.callbacks.History at 0x7f21c5938890>
```

```

1 model = Sequential()
2 model.add(LSTM(16, input_shape=(10,145), return_sequences=True))
3 model.add(Dropout(0.2))
4 model.add(LSTM(8, input_shape=(10,16), return_sequences=False))
5 model.add(Dropout(0.2))
6 model.add(Dense(4,activation='relu'))
7 model.add(Dense(1,activation='relu'))

```

```

1 model.compile(loss='mean_squared_error', optimizer='adam',metrics=["acc"])
2 model.fit(data_timestep, label_timestep, epochs=10,callbacks=[tensorboard_callback])

```

```

Epoch 1/10
8/8 [=====] - 4s 19ms/step - loss: 0.5731 - acc: 0.2423
Epoch 2/10
8/8 [=====] - 0s 21ms/step - loss: 0.2945 - acc: 0.5110
Epoch 3/10
8/8 [=====] - 0s 20ms/step - loss: 0.2324 - acc: 0.6432
Epoch 4/10
8/8 [=====] - 0s 19ms/step - loss: 0.2174 - acc: 0.7269
Epoch 5/10
8/8 [=====] - 0s 19ms/step - loss: 0.2328 - acc: 0.7181
Epoch 6/10
8/8 [=====] - 0s 20ms/step - loss: 0.2114 - acc: 0.7225
Epoch 7/10
8/8 [=====] - 0s 19ms/step - loss: 0.2109 - acc: 0.7181
Epoch 8/10
8/8 [=====] - 0s 23ms/step - loss: 0.2162 - acc: 0.6872
Epoch 9/10
8/8 [=====] - 0s 20ms/step - loss: 0.1986 - acc: 0.6960
Epoch 10/10
8/8 [=====] - 0s 20ms/step - loss: 0.2078 - acc: 0.7313
<keras.callbacks.History at 0x7f21c3daaed0>

```

```

1 model = Sequential()
2 model.add(LSTM(64, input_shape=(10,145), return_sequences=True))
3 model.add(Dropout(0.2))
4 model.add(LSTM(32, input_shape=(10,64), return_sequences=False))
5 model.add(Dropout(0.2))
6 model.add(Dense(8,activation='relu'))
7 model.add(Dense(1,activation='relu'))

```

```

1 model.compile(loss='mean_squared_error', optimizer='adam',metrics=["acc"])
2 model.fit(data_timestep, label_timestep, epochs=10,callbacks=[tensorboard_callback])

```

```

Epoch 1/10
8/8 [=====] - 4s 24ms/step - loss: 0.4035 - acc: 0.4229
Epoch 2/10
8/8 [=====] - 0s 23ms/step - loss: 0.2688 - acc: 0.7577
Epoch 3/10
8/8 [=====] - 0s 26ms/step - loss: 0.2018 - acc: 0.7357
Epoch 4/10
8/8 [=====] - 0s 23ms/step - loss: 0.1933 - acc: 0.7577
Epoch 5/10
8/8 [=====] - 0s 26ms/step - loss: 0.2035 - acc: 0.7621
Epoch 6/10
8/8 [=====] - 0s 24ms/step - loss: 0.1931 - acc: 0.7533
Epoch 7/10
8/8 [=====] - 0s 23ms/step - loss: 0.2082 - acc: 0.7401
Epoch 8/10
8/8 [=====] - 0s 26ms/step - loss: 0.1941 - acc: 0.7665
Epoch 9/10
8/8 [=====] - 0s 24ms/step - loss: 0.1930 - acc: 0.7445
Epoch 10/10
8/8 [=====] - 0s 24ms/step - loss: 0.1966 - acc: 0.7489
<keras.callbacks.History at 0x7f21c2bcba90>

```

استفاده از دو لایه GRU پشت سر هم :

```
1 model = Sequential()
2 model.add(GRU(16, input_shape=(10,145), return_sequences=True))
3 model.add(Dropout(0.2))
4 model.add(GRU(8, input_shape=(10,16), return_sequences=False))
5 model.add(Dropout(0.2))
6 model.add(Dense(4,activation='relu'))
7 model.add(Dense(1,activation='relu'))

1 model.compile(loss='mean_squared_error', optimizer='adam',metrics=["acc"])
2 model.fit(data_timestep, label_timestep, epochs=10,callbacks=[tensorboard_callback])
```


نتیجه مدل بر روی داده آموزش و ارزیابی آن:

```
Epoch 1/10
8/8 [=====] - 4s 20ms/step - loss: 0.5471 - acc: 0.3260
Epoch 2/10
8/8 [=====] - 0s 21ms/step - loss: 0.2971 - acc: 0.6828
Epoch 3/10
8/8 [=====] - 0s 19ms/step - loss: 0.2927 - acc: 0.6784
Epoch 4/10
8/8 [=====] - 0s 20ms/step - loss: 0.2715 - acc: 0.5771
Epoch 5/10
8/8 [=====] - 0s 21ms/step - loss: 0.2657 - acc: 0.6079
Epoch 6/10
8/8 [=====] - 0s 20ms/step - loss: 0.2533 - acc: 0.6828
Epoch 7/10
8/8 [=====] - 0s 19ms/step - loss: 0.2559 - acc: 0.6167
Epoch 8/10
8/8 [=====] - 0s 21ms/step - loss: 0.2495 - acc: 0.6388
Epoch 9/10
8/8 [=====] - 0s 21ms/step - loss: 0.2552 - acc: 0.7093
Epoch 10/10
8/8 [=====] - 0s 20ms/step - loss: 0.2399 - acc: 0.7137
<keras.callbacks.History at 0x7f21cfbdf790>
```


```
1 model.evaluate(X_test,y_test)
```

```
2/2 [=====] - 1s 9ms/step - loss: 0.2440 - acc: 0.5217
[0.24404744803905487, 0.52173912525177]
```

epoch\_loss  
tag: epoch\_loss



epoch\_acc  
tag: epoch\_acc



سه ابعاد مختلف: همانطور که مشاهده میشود حتی با ابعاد کم نیز نتیجه مطلوبی حاصل میشود درحالیکه وقتی ابعاد زیاد میشود دقت افت پیدا میکند

```
1 model = Sequential()
2 model.add(GRU(16, input_shape=(10,145), return_sequences=True))
3 model.add(Dropout(0.2))
4 model.add(GRU(8, input_shape=(10,16), return_sequences=False))
5 model.add(Dropout(0.2))
6 model.add(Dense(4,activation='relu'))
7 model.add(Dense(1,activation='relu'))
```

```
1 model.compile(loss='mean_squared_error', optimizer='adam',metrics=["acc"])
2 model.fit(data_timestep, label_timestep, epochs=10,callbacks=[tensorboard_callback])
```

```
Epoch 1/10
8/8 [=====] - 9s 20ms/step - loss: 0.4146 - acc: 0.5419
Epoch 2/10
8/8 [=====] - 0s 21ms/step - loss: 0.2941 - acc: 0.5066
Epoch 3/10
8/8 [=====] - 0s 19ms/step - loss: 0.2764 - acc: 0.5463
Epoch 4/10
8/8 [=====] - 0s 20ms/step - loss: 0.2739 - acc: 0.6608
Epoch 5/10
8/8 [=====] - 0s 19ms/step - loss: 0.2472 - acc: 0.6344
Epoch 6/10
8/8 [=====] - 0s 20ms/step - loss: 0.2430 - acc: 0.6388
Epoch 7/10
8/8 [=====] - 0s 19ms/step - loss: 0.2372 - acc: 0.6828
Epoch 8/10
8/8 [=====] - 0s 21ms/step - loss: 0.2179 - acc: 0.7137
Epoch 9/10
8/8 [=====] - 0s 21ms/step - loss: 0.2304 - acc: 0.6696
Epoch 10/10
8/8 [=====] - 0s 23ms/step - loss: 0.2265 - acc: 0.7004
<keras.callbacks.History at 0x7f21c0211d10>
```

```
1 model = Sequential()
2 model.add(GRU(32, input_shape=(10,145), return_sequences=True))
3 model.add(Dropout(0.2))
4 model.add(GRU(8, input_shape=(10,32), return_sequences=False))
5 model.add(Dropout(0.2))
6 model.add(Dense(4,activation='relu'))
7 model.add(Dense(1,activation='relu'))
```

```
1 model.compile(loss='mean_squared_error', optimizer='adam',metrics=["acc"])
2 model.fit(data_timestep, label_timestep, epochs=10,callbacks=[tensorboard_callback])
```

```
Epoch 1/10
8/8 [=====] - 5s 20ms/step - loss: 0.3538 - acc: 0.6035
Epoch 2/10
8/8 [=====] - 0s 23ms/step - loss: 0.2627 - acc: 0.6388
Epoch 3/10
8/8 [=====] - 0s 24ms/step - loss: 0.2622 - acc: 0.6520
Epoch 4/10
8/8 [=====] - 0s 22ms/step - loss: 0.2333 - acc: 0.6696
Epoch 5/10
8/8 [=====] - 0s 27ms/step - loss: 0.2469 - acc: 0.6167
Epoch 6/10
8/8 [=====] - 0s 27ms/step - loss: 0.2324 - acc: 0.6872
Epoch 7/10
8/8 [=====] - 0s 21ms/step - loss: 0.2240 - acc: 0.7225
Epoch 8/10
8/8 [=====] - 0s 20ms/step - loss: 0.2070 - acc: 0.6784
Epoch 9/10
8/8 [=====] - 0s 22ms/step - loss: 0.2232 - acc: 0.7269
Epoch 10/10
8/8 [=====] - 0s 24ms/step - loss: 0.2039 - acc: 0.7269
<keras.callbacks.History at 0x7f21c09abb90>
```

```

1 model = Sequential()
2 model.add(GRU(128, input_shape=(10,145), return_sequences=True))
3 model.add(Dropout(0.2))
4 model.add(GRU(8, input_shape=(10,128), return_sequences=False))
5 model.add(Dropout(0.2))
6 model.add(Dense(16,activation='relu'))
7 model.add(Dense(1,activation='relu'))

1 model.compile(loss='mean_squared_error', optimizer='adam',metrics=["acc"])
2 model.fit(data_timestep, label_timestep, epochs=10,callbacks=[tensorboard_callback])

```

```

Epoch 1/10
8/8 [=====] - 4s 30ms/step - loss: 0.3901 - acc: 0.4405
Epoch 2/10
8/8 [=====] - 0s 29ms/step - loss: 0.2241 - acc: 0.6696
Epoch 3/10
8/8 [=====] - 0s 31ms/step - loss: 0.2367 - acc: 0.6740
Epoch 4/10
8/8 [=====] - 0s 28ms/step - loss: 0.2192 - acc: 0.6784
Epoch 5/10
8/8 [=====] - 0s 30ms/step - loss: 0.2124 - acc: 0.7004
Epoch 6/10
8/8 [=====] - 0s 27ms/step - loss: 0.2189 - acc: 0.6740
Epoch 7/10
8/8 [=====] - 0s 30ms/step - loss: 0.2136 - acc: 0.6608
Epoch 8/10
8/8 [=====] - 0s 28ms/step - loss: 0.2192 - acc: 0.6872
Epoch 9/10
8/8 [=====] - 0s 31ms/step - loss: 0.2091 - acc: 0.6916
Epoch 10/10
8/8 [=====] - 0s 29ms/step - loss: 0.2155 - acc: 0.6696
<keras.callbacks.History at 0x7f21bf814e90>

```

همانطور که مشاهده میشود مدل LSTM با افزایش ابعاد دقت بهتری پیدا می کند ولی GRU در ابعاد پایین نتیجه مناسبی می دهد و بعد از مرحله ایی دقت افت پیدا می کند.