

۱. شبکه آموزشی مولد بر اساس دو شبکه **generator** و **discriminator** می باشد که بایکدیگر در رقابت می باشند شبکه **generator** از یک تصویر با ابعاد ثابت نويز شروع میشود و در هربار تلاش و گرفتن نتیجه کار خود تلاش به بهبود نتایج و نزدیک شدن به داده واقعی میکند در حالیکه **discriminator** تلاش دارد که تمایز بین داده واقعی و جعلی را تشخیص دهد.

تابع هدف در این بازی به صورت یک بازی **minmax** تعریف شده است که در آن شبکه **discriminator** میخواهد دقت خود را **max** کند تا بتواند عکس های واقعی را از عکس تقلبی تشخیص دهد در حال که شبکه **generator** سعی میکند با تولید نمونه های غیر واقعی، **discriminator** را به خطا بیاندازد تا آن ها به عنوان عکس واقعی بشناسد. این کار باید به صورتی انجام شود که پارامتر ها در جهتی تغییر کنند که امید ریاضی خطای **discriminator** افزایش یابد.

۲. کانولوشن معکوس یک عملیات ریاضی است، هدف استفاده از کانولوشن معکوس این است که دقیقاً عکس عمل کانولوشن را انجام دهیم؛ یعنی با داشتن نقشه‌ی ویژگی بتوانیم عکس ورودی را بازسازی کنیم. به این کار **Up-sampling** گفته می‌شود.

۳. در قسمت تابع فعالسازی برای شبکه مولد میتوان از نوعی از تابع **Relu** استفاده کرد اما این تابع برای خروجی نمیباشد که مقادیر زیر صفر را نیز تولید میکند به نام **Leaky ReLU** استفاده میشود. همچنین در خروجی مولد نیز از تابع **tanh** استفاده میشود تا مولد و جداکننده در رنج ۱ تا -۱ قرار گیرند.

برای شبکه جداکننده از تابع **LeakyReLU** و در لایه خروجی آن از تابع **sigmoid** استفاده می‌کنیم که تعیین کند خروجی جعلی یا واقعی می‌باشد.

در قسمت تابع هزینه از **cross entropy** استفاده میکنیم که اندازه گیری تفاوت بین دو توزیع احتمال برای یک متغیر تصادفی معین یا مجموعه ای از رویدادها است.

۴.

پیاده سازی FCGAN:

ابتدا دیتاست را دانلود کرده تغییر سایز داده و به تصاویر سیاه سفید تغییر داده سپس بین مقادیر -۱ تا ۱ نرمالایز کردیم و به **batch** های ۲۵۶ تایی تغییر دادیم .

سپس مدل **generator** که لایه های کاملاً متصل دارد را به صورت زیر داریم:

Model: "sequential"		
Layer (type)	Output Shape	Param #
=====		
dense (Dense)	(None, 256)	25856
leaky_re_lu (LeakyReLU)	(None, 256)	0
dense_1 (Dense)	(None, 512)	131584
leaky_re_lu_1 (LeakyReLU)	(None, 512)	0
dense_2 (Dense)	(None, 1024)	525312
leaky_re_lu_2 (LeakyReLU)	(None, 1024)	0
dense_3 (Dense)	(None, 3136)	3214400
=====		
Total params: 3,897,152		
Trainable params: 3,897,152		
Non-trainable params: 0		

و مدل **discriminator** را به صورت عکس **generator** تعریف کرده و آنرا در زیر داریم:

```
Model: "sequential_1"
Layer (type)                Output Shape                Param #
=====
dense_4 (Dense)              (None, 1024)                3212288
leaky_re_lu_3 (LeakyReLU)    (None, 1024)                0
dropout (Dropout)            (None, 1024)                0
dense_5 (Dense)              (None, 512)                524800
leaky_re_lu_4 (LeakyReLU)    (None, 512)                0
dropout_1 (Dropout)          (None, 512)                0
dense_6 (Dense)              (None, 256)                131328
leaky_re_lu_5 (LeakyReLU)    (None, 256)                0
dropout_2 (Dropout)          (None, 256)                0
dense_7 (Dense)              (None, 1)                  257
=====
Total params: 3,868,673
Trainable params: 3,868,673
Non-trainable params: 0
```

داده نویزی ایجاد کرده و آن را ابتدا به generator می دهیم :

```
generator = make_generator_model()

noise = tf.random.normal([1, latent_dim])
generated_image = generator(noise, training=False)
```

و سپس به discriminator می‌دهیم برای تصمیم گیری:

```
discriminator = make_discriminator_model()
decision = discriminator(generated_image)
print (decision)
```

```
tf.Tensor([[-0.00537442]], shape=(1, 1), dtype=float32)
```

تابع خطا هرکدام جداگانه به صورت زیر تعریف می‌شود خروجی تمام داده های واقعی ۱ و داده های جعلی ۰ میشود و در نهایت cross entropy محاسبه شده و جمع زده میشود برای خطای کل:

```
def discriminator_loss(real_output, fake_output):
    real_loss = cross_entropy(tf.ones_like(real_output), real_output)
    fake_loss = cross_entropy(tf.zeros_like(fake_output), fake_output)
    total_loss = real_loss + fake_loss
    return total_loss
```

```
def generator_loss(fake_output):
    return cross_entropy(tf.ones_like(fake_output), fake_output)
```

مراحل یادگیری مدل به صورت زیر می‌باشد ابتدا نویز تولید می‌شود و سپس با استفاده از discriminator خروجی تصویر و خروجی نویز گرفته میشود و خطای داده نویزی تولید شده توسط generator_loss گرفته شده همچنین خطای داده واقعی و جعلی discriminator_loss نیز گرفته میشود و از مشتق آنها برای آموزش استفاده میشود.

```
def train_step(images):
    noise = tf.random.normal([BATCH_SIZE, noise_dim])

    with tf.GradientTape() as gen_tape, tf.GradientTape() as disc_tape:
        generated_images = generator(noise, training=True)


        real_output = discriminator(images, training=True)
        fake_output = discriminator(generated_images, training=True)

        gen_loss = generator_loss(fake_output)
        disc_loss = discriminator_loss(real_output, fake_output)

    gradients_of_generator = gen_tape.gradient(gen_loss, generator.trainable_variables)
    gradients_of_discriminator = disc_tape.gradient(disc_loss, discriminator.trainable_variables)

    generator_optimizer.apply_gradients(zip(gradients_of_generator, generator.trainable_variables))
    discriminator_optimizer.apply_gradients(zip(gradients_of_discriminator, discriminator.trainable_variables))
```

نتیجه آموزش :



Epoch 182

پایاده سازی DCGAN:

ابتدا داده ها را دانلود کرده و سپس تغییر سایز می دهیم به ابعاد (96,96,3) ان ها را نرمالایز کرده به بازه بین -۱ تا ۱ و سپس ترتیب چینش داده ها را تغییر می دهیم و به دسته های ۱۲۸ تایی در می اوریم:

مدل generator که از لایه های Conv2D_transpose تشکیل شده به صورت زیر تعریف شده است :

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 2304)	297216
reshape (Reshape)	(None, 6, 6, 64)	0
conv2d_transpose (Conv2DTranspose)	(None, 6, 6, 512)	819200
batch_normalization (Batch Normalization)	(None, 6, 6, 512)	2048
re_lu (ReLU)	(None, 6, 6, 512)	0
dropout (Dropout)	(None, 6, 6, 512)	0
conv2d_transpose_1 (Conv2DTranspose)	(None, 12, 12, 256)	3276800
batch_normalization_1 (Batch Normalization)	(None, 12, 12, 256)	1024
re_lu_1 (ReLU)	(None, 12, 12, 256)	0
dropout_1 (Dropout)	(None, 12, 12, 256)	0
conv2d_transpose_2 (Conv2DTranspose)	(None, 24, 24, 128)	819200
batch_normalization_2 (Batch Normalization)	(None, 24, 24, 128)	512
re_lu_2 (ReLU)	(None, 24, 24, 128)	0
conv2d_transpose_3 (Conv2DTranspose)	(None, 48, 48, 64)	204800
batch_normalization_3 (Batch Normalization)	(None, 48, 48, 64)	256
re_lu_3 (ReLU)	(None, 48, 48, 64)	0
conv2d_transpose_4 (Conv2DTranspose)	(None, 96, 96, 32)	51200
batch_normalization_4 (Batch Normalization)	(None, 96, 96, 32)	128
re_lu_4 (ReLU)	(None, 96, 96, 32)	0
dense_1 (Dense)	(None, 96, 96, 3)	99


مدل discriminator را داریم:

Model: "sequential_1"

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 48, 48, 64)	3072
leaky_re_lu (LeakyReLU)	(None, 48, 48, 64)	0
conv2d_1 (Conv2D)	(None, 24, 24, 64)	65536
batch_normalization_5 (Batch Normalization)	(None, 24, 24, 64)	256
leaky_re_lu_1 (LeakyReLU)	(None, 24, 24, 64)	0
conv2d_2 (Conv2D)	(None, 12, 12, 128)	131072
batch_normalization_6 (Batch Normalization)	(None, 12, 12, 128)	512
leaky_re_lu_2 (LeakyReLU)	(None, 12, 12, 128)	0
conv2d_3 (Conv2D)	(None, 6, 6, 256)	524288
batch_normalization_7 (Batch Normalization)	(None, 6, 6, 256)	1024
leaky_re_lu_3 (LeakyReLU)	(None, 6, 6, 256)	0
flatten (Flatten)	(None, 9216)	0
dense_2 (Dense)	(None, 1)	9217

=====
Total params: 734,977
Trainable params: 734,081
Non-trainable params: 896

داده نویزی تولید کرده و آن را به generator میدهیم:



سپس به discriminator برای تصمیم گیری میدهیم:

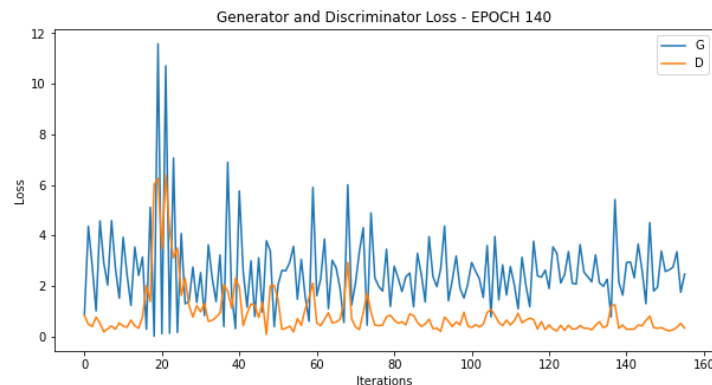
```
tf.Tensor([[0.49999946]], shape=(1, 1), dtype=float32)
```

تابع هزینه و عملیات آموزش مانده FCGAN می‌باشد:

نتیجه کار به صورت زیر می‌باشد :



تابع هزینه مدل generator و discriminator به صورت زیر می‌باشد:



یکی از مشکلات رایج در آموزش شبکه های مولد تقابلی همگرایی سریع discriminator نسبت به generator می باشد. اگر discriminator را ثابت فرض کنیم؛ در صورت کاهش تعداد لایه های generator، پیچیدگی آن نسبت به discriminator کمتر شده و سریع می تواند فرآیند یادگیری را طی کند و فرصت کافی برای آموزش دارد چرا که discriminator پیچیده بوده و آموزش آن نیازمند زمان می باشد و generator از این زمان استفاده کرده و خطای خود را کاهش می دهد اما در مقابل مسلماً میتوان انتظار داشت کیفیت تصاویر تولیدی نیز دچار کاهش خواهد شد.

۵.

۱. میتوان در هر تکرار مولد را آموزش بیشتری داد تا وزن ها چندین بار اصلاح شده و مقادیر بهتری بگیرند. یا میتوان لایه های مولد را کاهش داد تا زودتر به آموزشش همگرا شود و یا برعکس میتوان لایه های متمایز کننده را افزایش داد تا سرعت بخش discriminator کاهش یابد

۲. دسته جدا از تصاویر واقعی و جعلی، مدل تفکیک کننده با استفاده از نزول گرادیان تصادفی با مینی بچ ها آموزش داده می شود. بهترین روش این است که به جای ترکیب تصاویر واقعی و جعلی در یک دسته واحد، تشخیص دهنده را با دسته های جداگانه تصاویر واقعی و جعلی به روزرسانی کرد.

۳. از Label Smoothing استفاده کرد، استفاده از برچسب کلاس ۱ برای نمایش تصاویر واقعی و برچسب کلاس ۰ برای نمایش تصاویر جعلی هنگام آموزش مدل تفکیک کننده معمول است. اینها برچسب های سخت نامیده می شوند، زیرا مقادیر برچسب دقیق یا واضح هستند. استفاده از برچسب های نرم، مانند مقادیر کمی بیشتر یا کمتر از ۱.۰ یا کمی بیشتر از ۰.۰ به ترتیب برای تصاویر واقعی و جعلی، که در آن تغییرات برای هر تصویر تصادفی است.

۴. از برچسب های نویزی استفاده کرد برچسب هایی که هنگام آموزش مدل تمایز استفاده می شوند، همیشه صحیح هستند. این بدان معناست که تصاویر جعلی همیشه با کلاس ۰ و تصاویر واقعی همیشه با کلاس ۱ برچسب گذاری می شوند. توصیه می شود در این برچسب ها خطاهایی وارد شود که برخی از تصاویر جعلی به عنوان واقعی و برخی از تصاویر واقعی به عنوان جعلی مشخص شده اند. اگر از دسته های جداگانه برای به روزرسانی تشخیص دهنده تصاویر واقعی و جعلی استفاده می کنید، این ممکن است به معنای افزودن تصادفی برخی از تصاویر جعلی به دسته ای از تصاویر واقعی یا افزودن تصادفی برخی از تصاویر واقعی به دسته ای از تصاویر جعلی باشد. اگر تمایز کننده را با مجموعه ای از تصاویر واقعی و جعلی به روزرسانی می کنید، ممکن است به طور تصادفی برچسب ها را روی برخی از تصاویر تغییر دهید.

۶.

- در صورتی که نویز بسیار زیاد باشد مدل نمیتواند به خوبی یادگیری خود را انجام دهد و باعث از بین رفتن تعادل بین generator و discriminator میشود و در صورتی که نویز خیلی کم باشد نیز مدل به سرعت همگرا و شبکه فرصت یادگیری نخواهد داشت.
- با افزایش نویز، تصاویر تولید شده نیز دارای کمی نویز می باشند درحالیکه کم بودن نویز نیز باعث میشود تصاویر به خوبی یادگرفته نشوند و کیفیت پایین باشد.

۷. همانطور که از نتایج مشخص است خروجی شبکه DCGAN بهتر میباشد. تصاویر تولید شده با استفاده از معماری مدل DCGAN به طور قابل توجهی بهتر نسبت به تصاویر تولید شده با استفاده از شبکه تماماً متصل چندلایه GAN بودند. این را می توان به صورت زیر درک کرد: شبکه های عصبی کانولوشن، به طور کلی، مناطق همبستگی را در یک تصویر پیدا می کنند، یعنی به دنبال همبستگی های فضایی می گردند. این بدان معناست که یک DCGAN احتمالاً برای داده های تصویر/ویدئو مناسب تر است.